

Мультидисциплинарная молодёжная конференция «Научный телеграф»

Влияние параметра приоритизации α на качество DQN-агента self-play в игре «Уголки»

М. А. Самойлов

РОСБИОТЕХ, Москва samoilov_m1@yandex.ru

Почему α важен в self-play?


PER [Schaul et al., 2016] — заменяет равномерную выборку:

$$P(i) = \frac{(|\delta_i| + \varepsilon)^\alpha}{\sum_j (|\delta_j| + \varepsilon)^\alpha}$$

- $\alpha=0$ — обычный DQN (равномерно)
- $\alpha=0,6$ — стандарт Atari [Mnih, 2015]
- В **self-play**: соперник нестационарен
→ TD ошибки **преобладают**



Среда: «Уголки» — нулевая сумма, 4096 действий



Правила

Шаг (орт.) или прыжок через фишку.

Цепочки прыжков разрешены.

Ничья при ≥ 300 ходов.


Пространство действий

4 096 пар клеток (64×64);
нелегальные маскируются $-\infty$.

Кодирование состояния

Тензор $3 \times 8 \times 8$: свои / чужие /
цель

Метод: DQN + PER, абляция по α



Reward shaping:

+100 за победу / -100 за поражение

$+0,2 \times \Delta d$ прогресс к цели

-0,01 за каждый ход

Абляция:

$\alpha = 0$


$\alpha = 0,3$

$\alpha = 0,6$

$\alpha = 0,9$

$\alpha=0 \equiv$ равномерная выборка

Self-play: два игрока — одна сеть



Постановка эксперимента

Обучение

4 условия: $\alpha \in \{0; 0,3; 0,6; 0,9\}$

5 инициализаций $\times$ 1 500 эпизодов

Имитационный warm-start

Оценка

1 000 партий vs *Random*, *Greedy*, *Heuristic*

Метрика: $\text{wins} / (\text{wins} + \text{losses})$
(ничьи исключены)

95% bootstrap-ДИ, 10 000 ре-эмплеров

Базовые агенты:


Random — случайный легальный ход

Greedy — минимизирует $\sum$ Манхэттен


Heuristic — прогресс + прыжки + зоны

Все прочие гиперпараметры зафиксированы

Результаты: с ростом α качество падает



(а) Динамика $|\delta|$ — при $\alpha=0,9$ пик $\approx 21,4$. (б) Win rate с 95% CI.



α	Win rate	95% CI
0	71,8%	[70,5; 73,1]
0,3	69,4%	[68,0; 70,8]
0,6	60,9%	[59,5; 62,3]
0,9	53,1%	[51,6; 54,6]

$\Delta = +18,7$ п.п.

$\alpha=0$ vs $\alpha=0,9$

95% CI $\neq 0$

Итоговый win rate по результативным партиям

71,8%

$\alpha = 0$

(равном. выборка)



−18,7 п.п.

при росте α

53,1%

$\alpha = 0,9$

(макс. приоритет)

Тенденция монотонна; разностный bootstrap-ДИ не содержит нуль.

Выводы

✓ Win rate **монотонно убывает** с ростом α

✓ Разность $\alpha=0$ vs $\alpha=0,9$: **+18,7 п.п.**

✓ Высокий $\alpha \rightarrow$ пиковые $|\delta|$ и нестабильное обучение

Вывод: равномерная выборка ($\alpha=0$) оказалась оптимальной

Ограничения:

- Bootstrap-ДИ по партиям, не по seeds
- β -schedule не оптимизировался совместно с α
- Draw rate 57–74% влияет на метрику

Перспективы:

- Адаптивный α по динамике $|\delta|$

Спасибо за внимание!

Агрессивная приоритизация дестабилизирует self-play.

$\alpha=0$: 71,8% vs $\alpha=0,9$: 53,1%

Равномерная выборка победила в данной постановке.

М. А. Самойлов samoilov_m1@yandex.ru

Вопросы?