


Влияние параметра α в PER на качество DQN- self-play в «Уголках»

Абляционный анализ Prioritized Experience
Replay

Самойлов Михаил
@samoilov_ma
samoilov.m1@yandex.ru





Задача: игра «Уголки»

Постановка в self-play

Среда: игра «Уголки» на доске 8×8.

У каждого игрока 9 фишек.

Цель: быстрее перевести свои фишки в противоположный угол.

Максимум 300 ходов.

Игра детерминированная, с двумя игроками и нулевой суммой.

Техническая реализация

Состояние кодируется как тензор (8*8*3)

Действия: все пары клеток «откуда → куда»

Нелегальные действия маскируются значением $-\infty$.

Цикл обучения


Агент наблюдает состояние s .

Выбирает действие a .

Среда возвращает новое состояние s' и награду r .

Цель — максимизировать суммарную будущую награду.

В отличие от supervised learning, у агента нет правильного хода. Он получает только награду за последствия своих действий.



Q-функция и TD-ошибка

Что такое Q-функция?


$$Q(s, a) = \mathbb{E}[G_t \mid s_t = s, a_t = a], \quad G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}$$

Смысл: $Q(s, a)$ — ожидаемая суммарная дисконтированная награда, если в состоянии s выбрать действие a и затем следовать текущей стратегии.

Что такое TD-ошибка?

$$\delta = \underbrace{r + \gamma \max_{a'} Q(s', a')}_{\text{новая оценка}} - \underbrace{Q(s, a)}_{\text{старая оценка}}$$

Смысл: TD-ошибка — «удивление» агента: насколько реальный ход меняет его прогноз о ценности выбранного действия.



Связь с PER: чем больше $|\delta|$, тем «удивительнее» переход — тем чаще он попадает в обучающий батч.

Мини-теория

Определение через ожидаемую отдачу

$Q(s, a)$ — это оценка ожидаемой суммарной награды (отдачи) при том, что агент находится в состоянии s , выполняет действие a , а затем следует некоторой стратегии. Благодаря этому Q связывает выбор действия с будущими наградами в числовом виде.

Уравнение Беллмана и смысл Q

TD-ошибка показывает, насколько текущая оценка агента отличается от новой оценки после реального перехода:

Влияние параметра приоритизации α на DQN в self-play



Буфер опыта и дообучение

В DQN агент сохраняет переходы в буфере опыта (s, a, r, s') и затем дообучает сеть на отобранных переходах. В ordinary replay переходы из буфера выбираются равновероятно.



Формула приоритета и роль α

Вероятность выбора задаётся как $P(i) \propto p_i^\alpha$, где $p_i = |\delta_i| + \epsilon$. Тем самым α регулирует влияние приоритетов, основанных на величине ошибки, на частоту отбора.



self-play стабилизирует траектории

Так как игра детерминированная и с нулевой суммой. Изменение α меняет отбор обучающих переходов, но базовая целевая динамика сохраняется: $\alpha=0$ — равномерно, $\alpha \rightarrow 1$ — фокус на «ошибочных».

Почему используется DQN?

1

Игра «Уголки» — игра с нулевой суммой: 4096 возможных действий соответствуют парам клеток на поле 64×64 . Нелегальные ходы маскируются значением $-\infty$, выполнение — ортогональным шагом или прыжком через фишку.

2

Допускаются цепочки прыжков; ничья фиксируется после 300 ходов. Состояние кодируется тензором $3 \times 8 \times 8$: отдельные каналы для своих фишек, чужих фишек и цели, которую агент должен достигать.

3

DQN позволяет приблизить ценность действий в огромном пространстве состояний..

Мотивация: зачем это исследование?

Atari (DeepMind)

Агент обучается играть в **49 игр Atari**

Среда **фиксированная**:

правила и противник не меняются

Используется replay buffer:

агент переигрывает прошлый опыт

В PER переходы с большой TD-ошибкой
выбираются чаще

(экспериментально $\alpha = 0.6$)



Гипотеза исследования

1

PER считает переходы с большой TD-ошибкой более полезными для обучения.

2


Но в self-play соперник — это та же DQN-сеть, которая постоянно обновляется. Из-за этого старые переходы из буфера могут быстро устаревать.

3

Гипотеза:

чем выше α , тем сильнее PER фокусируется на устаревших «ошибочных» переходах и тем менее стабильным становится обучение.

Дизайн эксперимента




Эксперимент: меняем только α

Проверялись четыре значения: $\alpha \in \{0, 0.3, 0.6, 0.9\}$
Все остальные гиперпараметры фиксированы.

Турнир среди моделей

1000 партий против Greedy / Heuristic / Random
метрика — win rate
95% bootstrap confidence interval


Результаты win rate



**Разница между $\alpha = 0$ и $\alpha = 0.9$:
+18.7 процентных пункта.**

Почему PER мог ухудшить качество?

В self-play «сложный» не всегда
значит «полезный».



Но в self-play высокая TD-ошибка может означать, что переход был получен против старой версии агента.

При большой α такие переходы слишком часто попадают в обучение.

В результате градиент смещается в сторону устаревшего опыта, а обучение становится менее устойчивым.



Итог: $\alpha=0$ дал лучший результат в этой постановке

Главный итог:
Агрессивная приоритизация
дестабилизирует self-play в «Уголках».