

**ЗАВИСИМОСТЬ КАЧЕСТВА DQN-АГЕНТА SELF-PLAY
ОТ ПАРАМЕТРА ПРИОРИТИЗАЦИИ α
В ИГРЕ «УГОЛКИ»**

М. А. Самойлов^{1,*}

¹ Российский биотехнический университет (РОСБИОТЕХ), г. Москва
**email: samoilov_m1@yandex.ru*

Работа исследует влияние параметра степени приоритизации α в методе Prioritized Experience Replay (PER) на качество DQN-агента при обучении методом self-play в игре «Уголки». При $\alpha=0$ метод совпадает с равномерной выборкой. В экспериментах с бюджетом 1 500 эпизодов и 2 инициализациями на условие наблюдалась тенденция снижения доли побед с ростом α : $\alpha=0$ — 71,8%; $\alpha=0,3$ — 69,4%; $\alpha=0,6$ — 60,9%; $\alpha=0,9$ — 53,1%. Устойчивость тенденции требует проверки на большем числе запусков.

Ключевые слова: обучение с подкреплением, DQN, prioritized experience replay, аблационный анализ, self-play.

Актуальность. В PER [2] параметр α задаёт степень приоритизации: при $\alpha=0$ — равномерная выборка, при $\alpha=1$ — пропорциональная TD-ошибке. Стандартное значение $\alpha=0,6$ подобрано для задач Atari [1]; в self-play с нестационарным соперником его оптимальность неочевидна [3]. Аблационный анализ по α позволяет оценить чувствительность политики к этому гиперпараметру.

Метод. Среда — «Уголки» 8×8 , 9 фишек, ≤ 300 ходов. Состояние: тензор $3 \times 8 \times 8$; 4 096 Q-значений; нелегальные ходы маскировались $-\infty$; канонический разворот доски для обоих игроков. Архитектура: Conv $\times 2 \rightarrow$ Linear $\times 2$. Proportional PER:

$$p_i = |\delta_i| + \varepsilon, \quad P(i) = \frac{p_i^\alpha}{\sum_j p_j^\alpha}, \quad (1)$$

IS-веса β : 0,4 $\rightarrow$ 1,0. Варьировался один параметр: $\alpha \in \{0; 0,3; 0,6; 0,9\}$; прочие гиперпараметры DQN фиксированы; по 2 инициализации на условие; 1 500 эпизодов self-play. Оценка — 1 000 партий против Greedy/Heuristic/Rand с чередованием первого хода; метрика — доля побед в результативных партиях (ничьи исключены); 95% bootstrap-ДИ по партиям (10 000 ресэмпллов).

Результаты.




Рис. 1: (а) Динамика средней абс. TD-ошибки: с ростом α пик нарастает и сдвигается вправо. (б) Доля побед в результативных партиях по значениям α ; планки — 95% bootstrap-ДИ.

Рис. 1а: при $\alpha=0,9$ пик TD-ошибки $\approx 21,4$ (эп. ≈ 420); при $\alpha=0$ — монотонное убывание до $\approx 3,8$. По метрике (рис. 1б) наблюдалось снижение доли побед с ростом α : $\alpha=0$ — **71,8%** [70,5; 73,1], $\alpha=0,3$ — **69,4%** [68,0; 70,8], $\alpha=0,6$ — **60,9%** [59,5; 62,3], $\alpha=0,9$ — **53,1%** [51,6; 54,6]. Разность $\alpha=0$ и $\alpha=0,9$: +18,7 п.п.; bootstrap-ДИ не содержит нуля. Интервалы отражают вариативность по партиям; оценка дисперсии между инициализациями при $n=2$ ограничена.

Закключение. При бюджете 1 500 эпизодов наблюдалась тенденция снижения качества политики с ростом α : при $\alpha=0,3$ потери составили 2,4 п.п. (могут лежать в пределах вариативности между запусками), при $\alpha=0,6$ и $\alpha=0,9$ — 10,9 и 18,7 п.п. Это согласуется с гипотезой о дестабилизирующем влиянии агрессивной приоритизации в нестационарном self-play. Тенденция требует подтверждения при ≥ 5 инициализациях и бюджете $\geq 5\,000$ эпизодов. Перспективы: адаптивный α , совместный подбор α и β .

Список литературы

- [1] Mnih V. et al. Human-level control through deep reinforcement learning // Nature. — 2015. — Vol. 518. — P. 529–533.
- [2] Schaul T. et al. Prioritized Experience Replay // ICLR. — 2016.
- [3] Hessel M. et al. Rainbow: Combining Improvements in Deep RL // AAAI. — 2018. — P. 3215–3222.