

СРАВНЕНИЕ РАВНОМЕРНОГО И ПРИОРИТИЗИРОВАННОГО EXPERIENCE REPLAY ПРИ ОБУЧЕНИИ DQN-АГЕНТА В ИГРЕ «УГОЛКИ»

А. А. Самойлов^{1,*}

¹ Центральный университет

* email: samoilov@centraluniversity.ru

В работе сравниваются равномерная (Uniform Replay) и приоритизированная (PER) стратегии выборки из буфера воспроизведения при обучении DQN в игре «Уголки». Реализованы среда на доске 8×8 , агенты-базисы и воспроизводимый evaluation pipeline с bootstrap-оценкой доверительных интервалов по 1000 партиям на пару. Оба агента статистически значимо превосходят случайную игру; при этом Uniform Replay демонстрирует более высокий win rate (23,5% против 17,4% у PER, $p < 0,05$).

Ключевые слова: обучение с подкреплением, DQN, prioritized experience replay, игровые агенты, self-play.

Актуальность. DQN [1] стабилизирует обучение за счёт experience replay. Равномерная выборка не учитывает информативность переходов, тогда как PER [2] приоритизирует переходы с высокой TD-ошибкой, что теоретически ускоряет сходимость. Сравнение этих стратегий в настольных играх с дискретным замаскированным пространством действий остаётся практически неисследованным.

Постановка задачи. Среда — доска 8×8 с 9 фишками у каждого игрока; разрешены ортогональные ходы и прыжки, диагонали запрещены; цель — перенести фишки в противоположный угол. Исследуется влияние стратегии replay на качество выученной политики при фиксированном числе эпизодов self-play.

Метод. Состояние кодируется тензором $3 \times 8 \times 8$; нелегальные действия маскируются. Сеть всегда наблюдает позицию с точки зрения текущего игрока — это обеспечивает инвариантность к смене сторон. При PER приоритет и вероятность выборки перехода i :

$$p_i = (|\delta_i| + \varepsilon)^\alpha, \quad P(i) = \frac{p_i}{\sum_j p_j}, \quad (1)$$

где δ_i — TD-ошибка, $\varepsilon > 0$, $\alpha = 0,6$. IS-веса корректируют смещение с анилингом $\beta: 0,4 \rightarrow 1,0$ [2].

Экспериментальный протокол. По 1500 эпизодов self-play при 2 random seed; оба варианта используют общий warm-start от имитационного обучения. Оценка — 1000 партий на каждую пару (Uniform×2 seed, PER×2 seed против Random, Greedy, Heuristic). Доверительные интервалы win rate — 95% bootstrap (10 000 ресэмплов по отдельным партиям); для проверки превосходства используется bootstrap-ДИ разности.




Рис. 1: Динамика средней абсолютной TD-ошибки $|\delta|$ (скользящее среднее, $w=30$; полоса — 95% CI по seed). PER демонстрирует характерный пик на ранних эпизодах.

Результаты. Рис. 1 демонстрирует качественно различную динамику: при PER $|\delta|$ резко возрастает в начале обучения (до $\approx 12,7$), затем убывает — типичное поведение приоритизированной выборки, концентрирующей обновления на наиболее информативных переходах (1). Uniform Replay даёт гладкое монотонное убывание $|\delta|$.




Рис. 2: Win rate DQN-агентов против каждого соперника и суммарно (1000 партий на пару; планки — 95% bootstrap CI).

По итогам 6000 партий на каждую стратегию (рис. 2) Uniform Replay достиг суммарного win rate 23,5% [22,4%; 24,6%], PER — 17,4% [16,4%; 18,3%]. Доверительные интервалы не пересекаются, а bootstrap-ДИ разности составляет +6,1% [+4,6%; +7,5%]: ноль не входит в интервал, что подтверждает статистическую значимость превосходства Uniform Replay в данных условиях. При этом оба агента конкурентоспособны против рукописных базисов (рис. 3).




Рис. 3: Суммарный win rate каждого DQN-агента (по всем типам соперников). Пунктир — уровень случайной игры. 95% bootstrap CI.

Нижние границы 95% CI всех четырёх агентов (12,0% и выше) существенно превышают нулевой уровень случайной игры (рис. 3), то есть оба варианта DQN статистически значимо превосходят Random. В прямом матче лучший Uniform (seed 2) выиграл у лучшего PER (seed 2) на 1000 партиях.

Заключение. Реализованы среда «Уголки» для RL, агенты-базисы и воспроизводимый evaluation pipeline с bootstrap-статистикой. Оба обученных DQN-агента статистически значимо превосходят случайную игру и демонстрируют конкурентный уровень против рукописных стратегий. Uniform Replay показал значимо более высокий win rate при 1500 эпизодах self-play (+6,1%, ДИ разности не содержит нуля), что согласуется с известной чувствительностью PER к настройке гиперпараметров [3]. Проверка гипотезы о превосходстве PER в режиме большего числа эпизодов остаётся перспективой будущих исследований.

Список литературы

- [1] Mnih V. et al. Human-level control through deep reinforcement learning // Nature. — 2015. — Vol. 518. — P. 529–533.

- [2] *Schaul T., Quan J., Antonoglou I., Silver D.* Prioritized Experience Replay // ICLR. — 2016.
- [3] *Hessel M. et al.* Rainbow: Combining Improvements in Deep Reinforcement Learning // AAAI. — 2018. — P. 3215–3222.