

СРАВНЕНИЕ РАВНОМЕРНОГО И ПРИОРИТИЗИРОВАННОГО EXPERIENCE REPLAY ПРИ ОБУЧЕНИИ DQN-АГЕНТА В ИГРЕ «УГОЛКИ»

А. А. Самойлов^{1,*}

¹ Центральный университет

* email: samoilov@centraluniversity.ru

В работе сравниваются равномерная (Uniform Replay) и приоритизированная (PER) стратегии выборки из буфера воспроизведения при обучении DQN в игре «Уголки». Реализованы среда на доске 8×8 , агенты-базисы и pipeline для multi-seed оценки. Эксперименты выявляют качественно различную динамику TD-ошибки двух стратегий.

Ключевые слова: обучение с подкреплением, DQN, prioritized experience replay, игровые агенты, self-play.

Актуальность. DQN [1] стабилизирует обучение за счёт experience replay. Равномерная выборка не учитывает информативность переходов, тогда как PER [2] приоритизирует переходы с высокой TD-ошибкой, ускоряя сходимость.

Постановка задачи. Среда — доска 8×8 с 9 фишками у каждого игрока; разрешены ортогональные ходы и прыжки, диагонали запрещены; цель — перенести фишки в противоположный угол. Исследуется, ускоряет ли PER обучение DQN self-play по сравнению с Uniform Replay.

Метод. Состояние кодируется тензором $3 \times 8 \times 8$; нелегальные действия маскируются. Сравняются два DQN-агента с одинаковой архитектурой и target network, различающиеся только стратегией replay. При PER приоритет и вероятность выборки перехода i :

$$p_i = (|\delta_i| + \varepsilon)^\alpha, \quad P(i) = \frac{p_i}{\sum_j p_j}, \quad (1)$$

где δ_i — TD-ошибка, $\varepsilon > 0$, $\alpha \in [0, 1]$. IS-веса корректируют смещение с анилингом β : 0,4→1,0 [2].

Экспериментальный протокол. По 200 эпизодов self-play при 2 random seed. Оценка — круговой турнир DQN vs Random, Greedy, Heuristic (10 партий на пару). Метрики: win/draw rate, avg moves, динамика $|\delta|$ по эпизодам.



Рис. 1: Динамика средней абсолютной TD-ошибки $|\delta|$ за 200 эпизодов self-play (2 seed; линия — среднее, область — $\pm\text{std}$).

Результаты. Рис. 1 демонстрирует разительное различие: $|\delta|$ при PER растёт до ≈ 340 к 200-му эпизоду, тогда как при Uniform Replay остаётся $\approx 2,8$. При ограниченном числе эпизодов win rate обоих агентов равен нулю; однако draw rate DQN с PER выше и стабильнее ($0,98 \pm 0,02$ против $0,92 \pm 0,12$), что указывает на различие в выученном поведении.

Заключение. Вклад работы: реализованы среда «Уголки» для RL, агенты-базисы, сравнение Uniform/PER в единых условиях и воспроизводимый evaluation pipeline. Различия в динамике (1) подтверждают значимость стратегии replay; итоговая проверка гипотезы о sample efficiency требует экспериментов большего масштаба [3].

Список литературы

- [1] *Mnih V. et al.* Human-level control through deep reinforcement learning // Nature. — 2015. — Vol. 518. — P. 529–533.
- [2] *Schaul T., Quan J., Antonoglou I., Silver D.* Prioritized Experience Replay // ICLR. — 2016.
- [3] *Hessel M. et al.* Rainbow: Combining Improvements in Deep Reinforcement Learning // AAAI. — 2018. — P. 3215–3222.